




인공지능 미래 예측

인공지능을 활용한 데이터 기반 미래 예측

주)딥마인

- 목 차 -

AI Forecasting Principles and Practice

- 인공지능 예측 원리와 실제

ARIMA Forecasting Principles and Practice

- ARIMA 예측 원리와 실제

Deep Learning Time Series Principles and Practice


- 딥러닝 시계열 예측 원리와 실제

Foundation Forecasting Models Principles and Practice

- 파운데이션 예측 모델 원리와 실제

AI Forecasting Principles and Practice

인공지능 예측 원리와 실제



신의 영역에서 데이터의 영역으로



인류는 수천 년 동안 미래를 알고자 했습니다.


- 기원전700년: 이사야 선지자, '장차 당할 일을 보이라 너희가 신들인 줄 우리가 알리라'
- 고대바빌론: 양의 간(sheep's liver) 모양으로 미래를 점침
- 고대 델포이: 에틸렌 가스에 취한 신탁(Oracle)의 예언
- 1736년영국: 예언 대가로 돈을 받는 것을 사기죄로 규정 (3개월중노동형).




예측이 '마법'이 아닌 '과학'이 되어야 하는 이유는 전문가들도 자주틀리기 때문입니다.

- '세계적으로 컴퓨터 수요는 아마 5대 정도 일 것이다' (IBM회장, 1943)
- '미래의 컴퓨터는 무게가 1.5톤은 나갈 것이다.' (Popular Mechanics, 1949)
- '개인이 집에 컴퓨터를 둘 이유는 없다' (DEC회장, 1977- IBMPC출시 3년 전)


| 예측, 목표, 그리고 계획의 차이



가능한 모든 정보를 활용해 미래를
최대한 정확하게 추정하는 것
(예 : 내년 매출은 5% 성장할
것으로 보인다.)



예측을 목표에 일치시키기 위한
구체적인 대응 행동
(예: 예측과 목표의 차이를 메우기 위해
마케팅 예산을 늘린다.)



일어나기를 바라는 희망 사항
(예: '내년 매출을 20% 성장시키겠다.')

Key Insight: 비즈니스에서 이 세 가지를 혼동하면 비현실적인 목표를 계획 없이 설정하게 됩니다.
예측은 경영진의 의사결정(생산, 인사, 재무 계획)을 돕는 필수적인 도구입니다.


| 무엇을 예측할 수 있는가?

내일의 일출 시각은 정확히 알 수 있지만, 로또 번호는 알 수 없습니다. 예측 가능성은 다음 4가지 요인에 의해 결정됩니다.



1. 요인에 대한 이해 (Understanding Factors)

결과에 영향을 미치는
변수들을 우리가 얼마나 잘
알고 있는가?



2. 데이터의 가용성 (Data Availability)

얼마나 많은 과거 데이터가
존재하는가?



3. 과거와 미래의 유사성 (Similarity)

미래가 과거와 비슷하게 흘러
갈 것이라고 가정할 수 있는가?




4. 피드백 루프의 부재 (No Feedback Loop)

예측 자체가 결과에 영향
을 미치지 않는가?


예측 난이도의 스펙트럼

Case A: 전력수요 (Predictable)



- 조건 충족: 4가지 조건 모두 만족
- 이유: 기온(주요인)에 의해 주도되며, 수십 년간의 데이터 존재, 패턴이 일정함
- 결과: 매우 정확한 단기 예측 가능.

Case B: 환율 (Impossible)



- 조건 불충족: 데이터 '가용성' 외에는 충족되는 것이 없음
- 이유: 효율적 시장 가설 (Efficient Market Hypothesis) 작동
- 효율적 시장 가설: 예측이 가격에 즉시 반영되어, 미래의 등락은 동전 던지기(50%)와 같아짐

| 예측의 대상과 기간 설정

비즈니스 기능 (Business Function)	단기 (Short-term)	중기 (Medium-term)	장기 (Long-term)
	인사 스케줄링, 생산 계획, 수송 배차 (수요 예측 필수)	원자재 구매, 장비도입 예산, 인력 채용 (자원 계획)	신규 시장 진입, R&D투자, 전략적 계획 (기회 분석)

예측기간 (Time Horizon)

데이터결정 (Data Granularity)


- 제품 라인 전체 vs 개별 제품
- 전국 매장합계 vs 지역별
- 주간(Weekly) vs 월간(Monthly) vs 연간(Annual)

Note: 예측주기가 짧을수록 자동화된 시스템 (Python등) 이 필수적입니다.


| 정량적 예측과 시계열 데이터

- 정성적 기법 (Qualitative): 데이터가 없거나 부적절할때 (전문가 판단 등)
- 정량적 기법 (Quantitative): 수치 정보가 있고, 과거 패턴이 지속된다고 가정할 때

Cross-Sectional Data (횡단면 데이터)




Time Series Data (시계열 데이터) - Focus



| 예측 모형의 구조 (Model Architectures)

설명모형 (Explanatory Models)


$$ED = f(\text{Temp}, \text{Economy}, \text{Error})$$



변수 간의 인과 관계를 설명, 미래의 변수값을 먼저 예측해야 함

시계열 모형 (Time Series Models)


$$ED_{t+1} = f(ED_t, ED_{t-1}, \dots, \text{Error})$$



과거의 자신의 데이터를 기반으로 미래를 예측, 외생 변수 불필요

혼합모형 (Dynamic/Mixed)


$$ED_{t+1} = f(ED_t, \text{Temp}, \text{Error})$$



과거 데이터와 외부 변수를 결합

예측차트 읽는 법: 점 예측과 구간 예측

Case Study: 호주맥주생산량(Australian Beer Production)



점예측(Point Forecast):평균값


80% 예측구간
(실제값이 포함될 확률 80%)

95% 예측구간
(실제값이 포함될 확률 95%)

Insight : 예측 구간은 미래의 불확실성을 시각적으로 보여줍니다. 구간이 좁을수록 예측의 신뢰도가 높음을 의미합니다

| 변화하는 환경속의 예측


환경이 변한다고 예측이 불가능한 것은 아닙니다.
우리는 ‘환경이 변화하는 방식(Way in which things change)’
이 지속될 것이라고 가정합니다.”



우리가 지금 어디에 있고 어디로 향하는지 알 수 있다면, 무엇을 어떻게해야 할지 더 잘 판단할 수 있다.
- 에이브러햄 링컨 -

| 파이썬을 활용한 현대적 구현

Tech Stack



'StatsForecast'

빠르고 정확한 예측 엔진
AutoETS ARIMA
등 자동화된 모형 적합


'UtilsForecast'

시계열 데이터 처리 유틸리티
plot_series를 통한
시각화 및 전처리

복잡한 계산(계절성 분해, 모형 적합)을 자동화하여
분석가는 '문제정의'와 '해석'에 집중할 수 있게 해줍니다.


ARIMA Forecasting Principles and Practice

ARIMA 예측 원리와 실제




ARIMA 모델 마스터하기 : 예측 원리와 실전

 Python과 StatsForecast를 활용한 시계열 데이터 분석의 정석



자기회귀(Autoregression)부터 AutoARIMA 자동화까지
시계열 예측의 가장 강력한 도구를 완벽하게 이해합니다.

| ARIMA vs ETS : 데이터의 무엇을 보는가?



ETS (지수 평활법)

데이터의 추세와 계절성을 설명하는 데
초점을 둡니다.

ARIMA


데이터의 자기상관 즉 과거와 현재 데이터
간의 관계를 설명하는 데 초점을 둡니다.

선형 지수 평활 모델은 ARIMA의 특수한 경우이지만, 두 모델은 서로 상호 보완적인 접근 방식을 제공합니다.


| 예측을 위한 흔들리지 않는 기반: 정상성(Stationarity)

정상 시계열(Stationary Time Series)이란 평균, 분산 같은 통계적 특성이 시간이 지남에 따라 변하지 않는 데이터를 의미합니다. 예측 가능한 장기적 패턴(추세나 계절성)이 없어야 합니다.

White Noise(정상 시계열)



Google Stock Price (비정상시계열)




추세가 있거나 계절성이 뚜렷한 데이터는 비정상(Non-stationary) 데이터입니다
ARIMA를 적용하기 위해서는 먼저 이 데이터를 정상 상태로 만들어야 합니다.

비정상 데이터를 정상 데이터로: 차분 (Differencing)


$$y_t' = y_t - y_{t-1}$$

차분은 연속된 관측값 사이의 차이를 계산하는 것입니다.

Original Data
(비정상)



Differenced Data
(정상)



Technical Note:

- 로그 변환 (Logarithms): 분산(Variance)을 안정화하는 데 도움을 줍니다
- 차분 (Differencing): 평균(Mean)을 안정화하여 추세나 계절성을 제거합니다.

객관적인 검정: 단위근 검정 (Unit Root Tests)

KPSS검정

차분이 필요한지 객관적으로 판단합니다.

- 귀무 가설 (H_0) : 데이터가 정상 (Stationary)이다.
- $p\text{-value} < 0.05$: 귀무 가설 기각 → 차분 필요
- $p\text{-value} > 0.05$: 정상 데이터로 판단

statsforecast유틸리티

ndiffs(x)

데이터를 정상화하기 위해 필요한 1차 차분 횟수 계산

nsdiffs(x)

계절성 차분이 필요한지 여부 계산 (계절성 강도 F_s) 0.64 기준)

적절한 d값은 데이터가 정상성을 가질 때까지 수행한 차분의 횟수입니다.


구성 요소 1: 자기회귀모델 (AR- Autoregression)

오늘의 값은 어제의 값에 가중치를 둔 거울이다.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

Lagged values (과거의 자신)


AR(1)



Data oscillates simply.

차수 (Order): 얼마나 먼 과거까지 돌아볼 것인가?

AR(2)



Data shows more complex wave-like oscillation patterns.

| 구성 요소 2: 이동평균 모델 (MA- MovingAverage)


과거의 예측 오차를, 과거의 예측 오차를 통해 미래를 보정한다.

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Past Forecast Errors (과거의 예측 오차)

차수 (Order): 얼마나 과거의 오차까지 반영할 것인가?

이것은 단순한 데이터 평활화(Smoothing)가 아닙니다. 오차 항들의 가중 합을 통한 예측 모델입니다.



| 종합: 비계절성 ARIMA(p,d,q)

- AR (p): AutoRegressive (자기회귀)
- I (d): Integrated (차분)
- MA (q): MovingAverage (이동평균)

B 표기법:



$$By_t = y_{t-1}$$

이를 통해 복잡한 수식을 간결하게 표현합니다.

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - B)^d y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q) \varepsilon_t$$

Special Cases (특수한 경우)	
White Noise	ARIMA(0,0,0)
Random Walk	ARIMA(0,1,0)
Damped Trend	ARIMA(1,1,2)

모델 선택의 기술: ACF와 PACF해석



Rule of Thumb

AR(p) 모델 후보

ACF가 지수적으로 감소 (Decay)  / PACF에서 시차p이후 절단 (Spike cutoff) 

MA(q) 모델 후보

PACF가 지수적으로 감소 (Decay)  / ACF에서 시차 q 이후 절단 (Spike cutoff) 

중요: 데이터가 이미 차분(d)되어 정상성을 가진 상태에서 이 플롯들을 확인해야 합니다.

최적의 파라미터 추정: MLE와 AICc

MLE (Maximum Likelihood Estimation)

관측된 데이터를 얻을 확률이 가장 높은
파라미터($c, \phi, 0$)를 찾는 수학적 방법입니다.

AICc (Akaike Information Criterion)

$$AICc = -2 \log(L) + 2(p+q+k+1) + \text{correction}$$

1. 오차 감소 : 모델이 데이터를 얼마나 잘 설명하는가?
2. 복잡도벌점: 파라미터가 너무 많으면 페널티 부여
3. 결과 : AICc값이 낮을수록, 과적합(Overfitting) 없는 좋은 모델

중요: d(차분 차수)는 데이터 자체를 변화시키므로, AICc로 비교할 수 없습니다. p와 q선택에만 사용합니다.

| 주기를 다루는 힘 : 계절성 ARIMA(SARIMA)




ARIMA (p,d,q) X (P,D,Q)m

비계절성부분

계절성 부분 (m=주기)


1. 계절성 차분 (Seasonal Differencing): $Y_t - Y_{t-m}$
계절적 패턴을 먼저 제거하여 데이터를 단순화합니다.

2. 계절성 AR/MA: m의 배수 시차(12, 24...)에서
나타나는 자기상관을 모델링합니다.




| 자동화 알고리즘: Hyndman-Khandakar 알고리즘

Statsforecast의 AutoARTMA() 작동원리




데이터에서 예측까지: ARIMA모델링 워크플로우




모델 신뢰성 검증: 잔차 진단 (Residual Diagnostics)

좋은 모델이라면, 남은 잔차(Residuals)는 아무런 패턴이 없는 백색잡음(White Noise)이어야 합니다.


Residuals over Time



ACF of Residuals



Histogram of Residuals




체크리스트:

- ✓ ACF: 자기상관이 임계값 내에 있는가?
- ✓ 히스토그램: 정규 분포에 가까운가?
- ✓ Ljung-Box 검정: $p\text{-value} \geq 0.05$ (상관관계 없음)인가?


Deep Learning Time Series Principles and Practice

딥러닝 시계열 예측
원리와 실제



신경망을 활용한 시계열예측

원리부터 실전 적용까지: Python과 NeuralForecast 라이브러리 활용 가이드



패러다임의 전환 : 로컬 모델에서 글로벌 모델로

로컬 모델 (Local Models)



Model A




Model B




Model C



Model D




Model E



Model F


ARIMA나 ETS 같은 전통적인 방식은 각 시계열 데이터를 개별적으로 취급하여 모델링합니다. 대규모 데이터셋에서는 관리가 비효율적이며, 수작업 피쳐 엔지니어링이 필수적입니다.

글로벌 모델 (Global Models)




신경망(Neural Networks)은 여러 시계열 데이터에서 공통된 패턴(압축된 표현)을 학습합니다. 단 하나의 모델로 복잡한 상호작용과 대규모 데이터를 처리할 수 있어, 별도의 수작업 튜닝 없이도 강력한 예측이 가능합니다.

신경망의 학습 메커니즘



함수 (The Function)	입력 (Input X)	목표 (Goal)	출력 (Output Y)
$f_{\theta}(y_{[0:t]}, x_{[0:t+h]})$ $= \hat{y}_{[t+1:t+h]} y_{[t+1:t+h]}$	과거의 타겟 데이터(y)와 외생 변수(x)를 포함합니다.	입력 데이터의 압축된 표현 (representation)을 학습하여 조건부 분포 $P(Y X)$ 를 추정합니다.	예측 범위(h, Horizon)에 대한 미래 값입니다.

모델 최적화와 경사 하강법



손실 함수 (Loss Function, L)

예측값 $\hat{Y}$ 과 실제값 Y 의 차이를 측정하는 지표입니다.
학습의 목표는 이 L 을 최소화하는 것입니다.

경사 하강법 (Gradient Descent)

파라미터 θ 를 반복적으로 업데이트하여 손실을 줄여나가는 과정입니다.


학습률 (Learning Rate, α)

모델이 얼마나 빠르게 학습할지를 결정하는 중요한 하이퍼파라미터입니다.

$$\theta_{i+1} \leftarrow \theta_i - \alpha \frac{\delta L}{\delta \hat{Y}_\theta}$$

(파라미터는 손실 함수의 기울기 반대 방향으로 조정됨)

기본 아키텍처: 다층 퍼셉트론 (MLP)



구조

입력층 (Predictors)과 출력층 (Forecasts) 사이에 '은닉층 (Hidden Layers)'이 존재하는 구조입니다.


비선형성 (Non-linearity)

단순 선형 회귀와 달리, 은닉 뉴런은 시그모이드 (sigmoid)와 같은 비선형 활성화 함수를 통해 데이터의 복잡한 패턴과 이상치 (outlier)를 처리합니다.

수식

$$z_j = b_j + \sum w_{i,j} x_i \text{ (선형 결합)}$$
$$s(z) = \frac{1}{1 + e^{-z}} \text{ (활성화 함수)}$$


현대적 신경망 아키텍처의 종류



MLP Family

NHITS, NBEATS, MLP


빠르고 강력함, **Direct Forecasting** 방식



RNN Family

LSTM, GRU, DeepAR 순차적
데이터 처리에 강점


Recursive Forecasting 방식



Transformer Family

Autoformer, TFT, PatchTST

장기 의존성 (Long-term dependency)
학습에 유리



CNN Family

BiTCN

합성곱 (**Convolution**)을 이용한
패턴 인식.

Direct vs. Recursive: 모든 미래 시점을 한 번에 예측하는 Direct 방식 (MLP 등)은 오류 누적 (Error Propagation)이 적은 반면, 한 단계씩 예측하는 Recursive 방식 (RNN)은 계산 효율성이 높을 수 있습니다.

필수 전처리: 데이터스케일링


신경망은 입력 값의 범위에 민감합니다. 스케일링이 없으면 경사 하강법 학습 시 성능이 저하되거나 편향(Bias)이 발생할 수 있습니다.

Identity: 스케일링 없음
(결과: 편향 발생, 성능 저하)


Standard 평균과 표준편차 사용

Robust 추천 : 중앙값(Median)과 IQR(Interquartile Range) 사용
이상치(Outlier)에 강건함

Identity Scaling (Failure)




Robust Scaling (Success)



최적화 목표설정 : 손실함수

MAE (Mean Absolute Error)


$$\frac{1}{N} \sum |Y_i - \hat{Y}_i|$$



예측 분포의 중앙값(Median)을 최적화
이상치(Outliers)에 덜 민감함
NeuralForecast의 기본값

MSE (Mean Squared Error)

$$\frac{1}{N} \sum (Y_i - \hat{Y}_i)^2$$




예측 분포의 평균(Mean)을 최적화
제곱항으로 인해 이상치에 매우 민감함
스케일링된 데이터와 함께 사용 권장

불확실성 모델링 : 확률적 예측


점 예측(Point Forecast)을 넘어, 예측의 불확실성을 포함한 구간을 추정합니다.
DistributionLoss를 사용하여 전체 조건부 분포를 모델링할 수 있습니다.

```
loss = DistributionLoss(distribution="Normal",  
                        level=[80, 90])
```



주의: 학습 데이터의 변동성이 낮거나 모델이 과적합(Overfitting)된 경우, 예측 구간이 지나치게 좁게 형성되어 미래의 불확실성을 과소평가할 위험이 있습니다.

| 외부변수 활용 : Exogenous Variables



NeuralForecast는 이러한 변수들을 별도로 지정하여 모델이 복합적인 상관관계를 학습하도록 지원합니다.


하이퍼 파라미터 최적화 자동화

■ Problem

은닉층의 수, 노드 수, 학습률, 입력 크기 등 수동으로 설정해야 할 파라미터가 너무 많습니다.

■ Solution

Auto Models (예: AutoNHITS AutoMLP)




```
model = AutoNHITS(h=12, config=nhits_config, num_samples=20)
```


신경망 예측모델링 전략 체크리스트

- ☐ Data Scaling항상 **Robust Scaler** 를 사용하여 이상치에 대비하십시오.
- ☐ Architecture데이터 특성에 맞는 모델군(MLP Vs RNN Vs Transformer)을 선택하십시오. 시작은 **NHITS** 나 **MLP** 가 좋습니다.
- ☐ Loss Function중앙값 예측엔 **MAE** , 평균 예측엔 **MSE** , 불확실성 측정엔 **DistributionLoss** 를 정의하십시오.
- ☐ Context: 정적(**Static**), 과거(**Historic**), 미래(**Future**) 변수를 적극 활용하여 정보를 보강하십시오.
- ☐ Optimization:수동 튜닝 대신 **Auto** 모델을 활용하여 최적의 하이퍼파라미터를 찾으십시오.


| 결론: 데이터 주도적 예측의 미래



“복잡한 상호작용과 대규모 데이터를 다루는 현대의 예측 문제, 이제는 글로벌 신경망 모델이 해답입니다.”


Foundation Forecasting Models Principles and Practice

파운데이션 예측 모델
원리와 실제



트랜스포머 아키텍처와 시계열 데이터의 만남

기존 방식 (RNN/LSTM)




순차적 처리 (Sequential Processing)

병렬 처리 (Parallel Processing)

RNN이나 LSTM과 달리, 트랜스포머는 전체 입력 시퀀스를 병렬로 처리하여 확장성과 효율성을 극대화합니다.

트랜스포머 (Transformer)




동시 처리 및 모든 연결
(Simultaneous Processing & All-to-All Connection)

셀프 어텐션 (Self-Attention)

시퀀스 내에서 멀리 떨어진 데이터 포인트 간의 관계를 파악하여 장기 의존성(Long-range dependencies)을 효과적으로 학습합니다.

패러다임의 전환: 기반 모델 (Foundation Models)



정의 (Definition)

방대한 데이터셋으로 사전 학습(Pre-training)된 후, 특정 데이터셋에 대한 학습 없이도 예측을 수행하는 모델입니다.


핵심 역량 (Core Capabilities)

- 제로샷 (Zero-shot): 특정 데이터에 대한 추가 학습 없이 즉시 예측 가능.
- 준지도 사전학습: 레이블이 없는 방대한 데이터에서 일반적인 패턴을 학습.

이점 (Benefits)

사용 편의성 및 연산 비용 절감.
제한된 데이터(Limited data)에서도 높은 정확도 달성.

전이 학습 (Transfer Learning)의 메커니즘



$$f_{\theta} : X \mapsto Y$$

Where $X = \{y_{[0:t]}, x_{[0:t+h]}\}$ and $Y = \{y_{[t+1:t+h]}\}$

개념 : 소스 데이터셋에서 학습된 지식을 타겟 데이터셋의 예측 문제 해결에 적용합니다.

요구사항 : 다양한 도메인의 폭넓고 깊이 있는 데이터셋을 통한 스케일링 법칙(Scaling Laws) 활용이 필수적입니다.


전이 학습 실습 : M4에서 항공승객 데이터까지

```
# Pre-training on M4 dataset
```

```
nf.fit(df=Y_df)
```

```
# Zero-shot prediction on unseen 'air_passengers' data
```

```
transfer_preds = nf.predict(df=air_passengers_df)
```



모델이 해당 데이터셋을 학습하지 않았음에도 불구하고, 시계열의 전반적인 움직임과 계절성을 정확히 포착했습니다.

| 기반 예측모델의 타임라인 및 생태계

2023

- Time-LLM
- TimeGPT-1 (Proprietary)
- Lag-Llama (Open Source)
- TimesFM (Proprietary)

2024

- Tiny Time Mixers (TTM) (Open Source)
- Moirai (Open Source)
- MOMENT
- UniTS
- Chronos (Open Source)

2023년을 기점으로 트랜스포머 기반의 시계열 모델 연구가 폭발적으로 증가했습니다.

■ = Proprietary ● = Open Source


Deep Dive I : TimeGPT (인코더-디코더 구조)

구조: 인코더-디코더 (Encoder-Decoder)
트랜스포머

특징: 잔차 연결 (Residual connections)
및 층 정규화 (Layer normalization)
포함 No Sans KR Regular

입력처리: 과거 데이터 윈도우 + 로컬 위치
인코딩 (Local positional encoding)

학습 규모: 1,000억 (100B+) 개 이상의
데이터 포인트 (금융, 날씨, 에너지, IoT 등)




Deep Dive II: 확률적 모델과 LLM의 활용

Lag-Llama 디코더 전용 (Decoder-only)


인코더 없이 과거의 시차 특성(Lagged features)을 입력받아 바로 예측생성.

스튜던트t-분포(Student's t-distribution)를 가정하여 불확실성 추정.




Chronos (Amazon) 토큰화 및 LLM 활용

시계열 데이터를 고정된 '어휘(Vocabulary)'로 토큰화하여 LLM(T5)이 처리. 언어 모델을 시계열 예측에 재사용 (Repurposing).



Deep Dive III: 패치 (Patching)와 효율성



패치(Patching) - 데이터 포인트를 그룹화하여 국소적인 의미 정보를 추출하고 연산량을 줄이는 기법.

TimesFM (Google)	디코더 기반, 결정론적 (Deterministic) 점 예측.
Tiny Time Mixers (IBM)	경량화 모델(1M파라미터), CPU실행 최적화
Moirai (Salesforce)	인코더 전용, 혼합 분포(Mixture distribution)를 사용한 확률적 예측

| 사례 연구 : 전력 가격 예측 (Electricity Price Forecasting)


도전 과제 (The Challenge)

노드 풀(Nord Pool) 전력 시장 데이터


- 높은 변동성(Volatility), 마이너스 가격, 급격한 가격 스파이크

데이터 구조 (Data Structure)

- 타겟 (y): 시간당 전력 가격
- 외생 변수 (x): 일일 부하 예측, 풍력 발전량
- 달력 정보: 요일, 원-핫 인코딩




TimeGPT 제로샷(Zero-shot) 예측 성능



MAE (평균 절대 오차): 1.902

분석: 튜닝없이도 시계열의
대략적인 패턴을 따라가지만,
파인튜닝을 통해 개선할 여지
가 있음

| 파인튜닝(Fine-tuning)을 통한 성능 최적화




~~MAE: 1.902~~ → 1.886


인사이트 : 파인튜닝은 기반 모델이 **개별데이터셋**의 **고유한 동적 특성(Dynamics)**을 학습하도록 도와 성능을 향상시킵니다.

| 외생 변수(Exogenous Variables)의 통합

- 개념 :과거 데이터뿐만 아니라, 미래의 부하(Load) 및 풍력(Wind) 예측 정보를 모델에 입력.
- 모델에 입력 결과 : 외생 변수를 활용함으로써 이전에는 포착하지 못했던 데이터의 변동(Variation)과 스파이크를 정확하게 예측합니다



모델 비교: Moirai (Salesforce)와 확률적 예측



Moirai 특징 : 확률적 접근(Probabilistic approach) 분포(Distribution)를 출력하므로 중앙값(Median)을 포인트 예측으로 사용.

결론 : 두 기반 모델 모두 복잡한 외부 변수를 효과적으로 처리하며, 사용자는 모델의 특성 (결정론적 vs 확률적)에 따라 선택 가능합니다.

| 결론: 시계열 예측의 새로운 표준

1.

진입장벽 감소

데이터별 모델개발 없이도
고성능 예측가능.

2.

제로샷 및 파인튜닝

범용성과 특화 성능의 균형을
맞춘 유연한 워크플로우.

3.

복잡성처리

외생 변수 및 다양한 데이터분포
처리 능력 입증.



Nixtla와 Salesforce 등의 벤치마크 결과에 따르면, 기반 모델은 지속적으로 발전하고 있으며 산업 전반의 예측 방식을 재정의할 잠재력을 가집니다.